



Support vector machines

Андрей Рудометов, 23221




Основные идеи

- “kernel functions” - основанное на скалярном произведении обобщение “схожести” для эффективного разделения в нелинейных областях.
- Задача квадратичного программирования для избежания локальных минимумов


Основные идеи

- Поиск гиперплоскости, если линейно разделимо
- Преобразование в другое пространство и поиск там, если нет (“kernel functions”)




Опорные векторы

- для разделения достаточно лишь крайних точек, а не всего класса
- хотим максимизировать расстояние от гиперплоскости до ближайшей точки
- в двумерных примерах гиперплоскость - линия, но вообще говоря нет



Опорные векторы


- Почему векторы, а не точки?



Как делить?

- w - нормаль к плоскости
- несложно посчитать, что расстояние $H_1 - H_2$ это $2 / ||w||$
- Значит, надо минимизировать $||w||$
- При условии, что между плоскостями нет точек:

$$\left. \begin{array}{l} x_i \cdot w + b \geq +1 \text{ when } y_i = +1 \\ x_i \cdot w + b \leq -1 \text{ when } y_i = -1 \end{array} \right\}$$





Что решать?

- \mathbf{x} - вектор, c - класс (например, -1 или 1)
- задача с ограничением
- двойственная задача поиска седловой точки функции Лагранжа

$$\{(\mathbf{x}_1, c_1), (\mathbf{x}_2, c_2), \dots, (\mathbf{x}_n, c_n)\}$$

$$\begin{cases} \|\mathbf{w}\|^2 \rightarrow \min \\ c_i(\mathbf{w} \cdot \mathbf{x}_i - b) \geq 1, \quad 1 \leq i \leq n. \end{cases}$$

$$\begin{cases} \mathbf{L}(\mathbf{w}, \mathbf{b}; \lambda) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \lambda_i (c_i((\mathbf{w} \cdot \mathbf{x}_i) - b) - 1) \rightarrow \min_{w,b} \max_{\lambda} \\ \lambda_i \geq 0, \quad 1 \leq i \leq n \end{cases} \quad (2)$$



Как использовать ответ?

- с только двойственными переменными

$$\begin{cases} -\mathbf{L}(\lambda) = -\sum_{i=1}^n \lambda_i + \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j c_i c_j (\mathbf{x}_i \cdot \mathbf{x}_j) \rightarrow \min_{\lambda} \\ \lambda_i \geq 0, \quad 1 \leq i \leq n \\ \sum_{i=1}^n \lambda_i c_i = 0 \end{cases} \quad (3)$$

- тогда найдем вектора плоскости как


$$\mathbf{w} = \sum_{i=1}^n \lambda_i c_i \mathbf{x}_i \quad \mathbf{b} = \mathbf{w} \cdot \mathbf{x}_i - c_i, \quad \lambda_i > 0$$

- итоговый алгоритм классификации:


$$a(x) = \text{sign} \left(\sum_{i=1}^n \lambda_i c_i \mathbf{x}_i \cdot \mathbf{x} - b \right) \quad (4)$$

А что если нелинейно?



- Поиск гиперплоскости, если линейно разделимо
- Преобразование в другое пространство и поиск там, если нет (“kernel functions”)





А что если нелинейно?



А что если нелинейно?




А что если нелинейно?



Как еще можно отображать?

- полиномы
- гауссовы функции
- сигмоида




$$K(\mathbf{x}, \mathbf{y}) = (\mathbf{x} \cdot \mathbf{y} + 1)^p$$

$$K(\mathbf{x}, \mathbf{y}) = \exp \left\{ -\frac{\|\mathbf{x} - \mathbf{y}\|^2}{2\sigma^2} \right\}$$


$$K(\mathbf{x}, \mathbf{y}) = \tanh(\kappa \mathbf{x} \cdot \mathbf{y} - \delta)$$

Еще примеры



Еще примеры

- Нелинейная радиально-базисная функция





Преимущества

- при больших размерностях
- $R^N > \text{samples}$
- подмножество samples
- разные определения схожести и комбинации kernel functions для уточнения



Недостатки

- плохо работает при $\text{features} > \text{samples}$
- не дает напрямую вероятностей принадлежности классу



Спасибо за внимание